


BART, TCN

Bart

Bart는 기존에 있던 GPT, BERT의 Generalization 두개를 이어 붙이 seq2seq encoder, decoder 구조를 가지고 있다.

내가 생각하는 BART의 핵심 의의는 BERT에서 masking token으로 확장되는 학습방식을 확장시켜, 다양한 corruption, restoration을 가능하게 하여 더욱 문맥을 잘 파악하는 성능을 가질수 있었다는 것이다. 이와 같은 학습을 위해 단순 encoder, decoder만을 쓰는 것이 아닌 encoder와 decoder를 결합시킨 conditional LM을 구축하여 더욱 복잡한 학습을 가능하게 하였다.



TCN

TCN은 transformer 개념이 나오기 전 RNN계열의 장기 의존성 문제를 CNN approach로 해결을 할수 있음을 보여주었다.

미래의 정보가 과거의 결과에 영향을 주지 않는다는 제약을 깔고 3가지 핵심 구성요소를 토대로 모델을 구축 하였다.

Causal Convolutions

시점 t의 출력이 이전 레이어의 t 시점 및 그 이전의 값들과만 합성곱 되도록 설계하여 인과적 제약을 구조적으로 보장하지만 이것만으로는 긴 시퀀스를 처리하기 위해 네트워크가 매우 깊어져야 하는 한계가 있습니다.

Dilated Convolutions

causal convolution의 한계를 극복하기 위해 일정한 간격(dilation)을 두고 데이터를 건너뛰며 합성곱을 적용하게 하였다. d를 지수적으로 증가시켜 수용 영역(receptive field)을 기하급수적으로 확장합니다. 이를 통해 적은 수의 층으로도 매우 넓은 범위의 과거 정보를 효율적으로 학습하게 하였다.

Residual Connections

네트워크가 깊어질수록 발생할 수 있는 학습 불안정 문제를 해결하기 위해 사용됩니다. 팽창 인과적 컨볼루션 레이어 주변에 스킵 연결을 추가하여 이 문제를 해결했습니다.




Figure 1. Architectural elements in a TCN. (a) A dilated causal convolution with dilation factors $d = 1, 2, 4$ and filter size $k = 3$. The receptive field is able to cover all values from the input sequence. (b) TCN residual block. An 1×1 convolution is added when residual input and output have different dimensions. (c) An example of residual connection in a TCN. The blue lines are filters in the residual function, and the green lines are identity mappings.