


ViT, YOLO

YOLO

YOLO는 객체 탐지(Object Detection) 문제를 기존의 복잡한 다단계 파이프라인이 아닌, Regression 문제로 재해석한 모델입니다. 이미지 전체를 한 번만 보고 각 객체의 Bounding Box와 클래스 확률을 동시에 예측합니다.

YOLO의 핵심 의의는

탐지 파이프라인을 하나의 신경망으로 통합하여 극적으로 속도를 높였다는 점입니다. 이전의 R-CNN 계열 모델들이 여러 단계를 거치며 속도가 느렸던 반면, YOLO는 단일 네트워크 평가만으로 실시간 객체 탐지를 가능하게 했습니다.



YOLO는 다음과 같은 과정으로 작동합니다.

- **Grid System:** 이미지를 S×S 그리드로 나눕니다. 객체의 중심이 특정 그리드 셀에 위치하면, 해당 셀이 그 객체를 탐지할 책임을 갖게 됩니다.
- **Unified Prediction:** 각 그리드 셀은 B개의 경계 상자과 각 상자에 대한 Confidence Score, 그리고 C개의 클래스 Class Probability를 직접 예측합니다. 이 모든 과정이 하나의 통합된 신경망에서 동시에 이루어집니다.

ViT는 자연어 처리 분야를 장악했던 트랜스포머 아키텍처를 이미지 인식 분야에 직접 적용한 모델입니다. 기존 컴퓨터 비전 분야의 표준이었던 CNN의 구조적 의존성을 탈피할 수 있음을 보여주었습니다.

ViT의 핵심 의의는

대규모 데이터셋으로 사전 학습할 경우, CNN이 가진 고유의 Inductive Bias 없이도 뛰어난 성능을 달성할 수 있음을 입증한 것입니다. CNN은 locality, translation equivariance와 같은 편향이 내장되어 적은 데이터로도 잘 작동하지만, ViT는 이러한 편향 없이도 방대한 데이터로부터 직접 이미지의 패턴과 구조를 학습할 수 있음을 보여주었습니다.

ViT는 다음과 같은 핵심 구성요소를 통해 이미지를 처리합니다.




Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable “classification token” to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

1. Image as a Sequence of Patches

이미지를 고정된 크기의 여러 패치로 분할한 뒤, 각 패치를 평탄화하여 1차원 벡터 시퀀스로 만듭니다. 이는 NLP에서 문장을 단어의 시퀀스로 다루는 것과 동일한 방식입니다.

2. Patch & Position Embeddings

이 패치 벡터들은 학습 가능한 linear projection을 통해 임베딩되고, 각 패치의 원래 위치 정보를 보존하기 위해 position embedding이 추가됩니다.

3. Transformer Encoder & Classification

패치와 위치 정보가 결합된 벡터 시퀀스는 표준 트랜스포머 인코더에 입력됩니다. 분류를 위해 BERT처럼 시퀀스 맨 앞에 학습 가능한

[class] 토큰을 추가하고, 트랜스포머를 통과한 후 이 토큰의 출력값을 이미지 전체의 대표 값으로 사용하여 최종 클래스를 예측합니다.